

Datasheet para Dataset de Sons Pulmonares

Letícia Lopes Mendes da Silva
Rafael Ávila dos Santos
Sofia Ballerini de Vasconcellos

Adaptado do template “Datasheets for Datasets”
desenvolvido por Christian Garbin

May 18, 2026

Sobre este documento

Este documento segue a proposta de [Datasheets for Datasets](#), que busca padronizar a documentação de conjuntos de dados utilizados em aprendizado de máquina, promovendo maior transparência, reprodutibilidade e entendimento sobre limitações, processos de coleta e usos recomendados dos dados.

O template original utilizado como base foi desenvolvido por Christian Garbin e adaptado neste trabalho para documentar os datasets de sons pulmonares utilizados no projeto.

Datasheet

Motivação

Por qual propósito o dataset foi criado? Tem alguma tarefa específica em mente? Tem algum gargalo que precisa ser preenchido? Por favor, forneça uma descrição.

Quem criou esse dataset (por exemplo, qual time, grupo de pesquisa) e em nome de qual entidade (por exemplo, companhia, instituição, organização)?

Quem financiou a criação do dataset? If there is an associated grant, please provide the name of the

grantor and the grant name and number.

Algum outro Comentário?

Composição

O que representam as instâncias que compõem o dataset (por exemplo, documentos, fotografias, pessoas, países)? Existem vários tipos de instâncias (por exemplo, filmes, usuários e classificações; pessoas e interações entre elas; nós e bordas)? Por favor, forneça uma descrição.

Quantas instâncias há no total (de cada tipo, se apropriado)?

Does the dataset contain all possible instances or is it a sample (not necessarily random) of instances from a larger set? If the dataset is a sample, then what is the larger set? Is the sample representative of the larger set (e.g., geographic coverage)? If so, please describe how this representativeness was validated/verified. If it is not representative of the larger set, please describe why not (e.g., to cover a more diverse range of instances, because instances were withheld or unavailable).

What data does each instance consist of? “Raw”

data (e.g., unprocessed text or images) or features? In either case, please provide a description.

Is there a label or target associated with each instance? If so, please provide a description.

Is any information missing from individual instances? If so, please provide a description, explaining why this information is missing (e.g., because it was unavailable). This does not include intentionally removed information, but might include, e.g., redacted text.

Are relationships between individual instances made explicit (e.g., users' movie ratings, social network links)? If so, please describe how these relationships are made explicit.

Are there recommended data splits (e.g., training, development/validation, testing)? If so, please provide a description of these splits, explaining the rationale behind them.

Are there any errors, sources of noise, or redundancies in the dataset? If so, please provide a description.

Is the dataset self-contained, or does it link to or otherwise rely on external resources (e.g., websites, tweets, other datasets)? If it links to or relies on external resources, a) are there guarantees that they will exist, and remain constant, over time; b) are there official archival versions of the complete dataset (i.e., including the external resources as they existed at the time the dataset was created); c) are there any restrictions (e.g., licenses, fees) associated with any of the external resources that might apply to a future user? Please provide descriptions of all external resources and any restrictions associated with them, as well as links or other access points, as appropriate.

Does the dataset contain data that might be considered confidential (e.g., data that is protected by legal privilege or by doctor-patient confidentiality, data that includes the content of individuals non-public communications)? If so, please provide a description.

Does the dataset contain data that, if viewed directly, might be offensive, insulting, threatening, or might otherwise cause anxiety? If so, please describe why.

Does the dataset relate to people? If not, you may skip the remaining questions in this section.

Does the dataset identify any subpopulations (e.g., by age, gender)? If so, please describe how these subpopulations are identified and provide a description of their respective distributions within the dataset.

Is it possible to identify individuals (i.e., one or more natural persons), either directly or indirectly (i.e., in combination with other data) from the dataset? If so, please describe how.

Does the dataset contain data that might be considered sensitive in any way (e.g., data that reveals racial or ethnic origins, sexual orientations, religious beliefs, political opinions or union memberships, or locations; financial or health data; biometric or genetic data; forms of government identification, such as social security numbers; criminal history)? If so, please provide a description.

Any other comments?

Processo de Coleta

Como os dados associados a cada instância foram adquiridos? Os dados eram diretamente observáveis (por exemplo, texto bruto, imagens), reportados pelos indivíduos (por exemplo, respostas

de formulários) ou inferidos/derivados indiretamente de outros dados (por exemplo, estimativas feitas por modelos)? Caso os dados tenham sido reportados pelos indivíduos ou inferidos/derivados de outros dados, eles foram validados/verificados? Se sim, descreva como.

Os dados eram diretamente observáveis. Foram adquiridos por meio de gravações de sons respiratórios utilizando estetoscópios eletrônicos e digitais, posicionados sobre vários pontos do tórax, com eventual uso de microfones. Os datasets utilizados neste trabalho (ICBHI e KAUH) disponibilizam os áudios juntamente com anotações clínicas realizadas por especialistas experientes da área da saúde, incluindo médicos e fisioterapeutas.

Quais mecanismos ou procedimentos foram utilizados para coletar os dados (por exemplo, sensores, curadoria manual humana, programas de software ou APIs)? Como esses mecanismos ou procedimentos foram validados?

No ICBHI, as gravações foram realizadas com estetoscópios digitais Welch Allyn Meditron Master Elite Plus, 3M Littmann Classic II SE e microfones acoplados ao sistema CLASS (Computerised Lung Auscultation – Sound System). No KAUH, foi utilizado o estetoscópio eletrônico 3M Littmann Electronic Stethoscope Model 3200, com transferência para um computador utilizando o software Littmann StethAssist. Ambos os trabalhos informam que as coletas seguiram protocolos clínicos e diretrizes de aquisição de sons respiratórios. Não foram encontradas descrições de validação formal dos equipamentos além do uso clínico especializado.

Se o dataset for uma amostra de um conjunto maior, qual foi a estratégia de amostragem utilizada (por exemplo, determinística ou probabilística com probabilidades específicas de amostragem)

Os dois datasets correspondem a amostras obtidas nos próprios ambientes clínicos e hospitalares.

Quem esteve envolvido no processo de coleta de dados (por exemplo, estudantes, crowdworkers, contratados) e como essas pessoas foram compensadas (por exemplo, quanto receberam)?

No ICBHI, participaram equipes de pesquisa da University of Aveiro (Lab3R) e da Aristotle University of Thessaloniki (AUTH), incluindo médicos e fisioterapeutas respiratórios. No KAUH, participaram pesquisadores e profissionais associados ao King Abdullah University Hospital e à Jordan University of Science and Technology. Não foram encontradas informações sobre compensação financeira.

Durante qual período os dados foram coletados? Esse período corresponde ao período de criação dos dados associados às instâncias (por exemplo, coleta recente de dados antigos)? Caso contrário, descreva o período em que os dados associados às instâncias foram criados.

Não foram encontradas informações sobre o período exato de aquisição dos dados. Para o ICBHI, é mencionado que os dados foram coletados ao longo de vários anos por diferentes estudos

Foi realizado algum processo de revisão ética (por exemplo, por um comitê de ética institucional)? Se sim, forneça uma descrição desses processos de revisão, incluindo os resultados e links ou meios de acesso para documentação de suporte.

Sim. O ICBHI informa que houve aprovação pelos comitês de ética das instituições responsáveis, embora não tenham citado as instituições, nem detalhes sobre o processo. O KAUH informa aprovação pelo Institutional Review Board do King Abdullah University Hospital e da Jordan University of Science and Technology (Ref. 91/136/2020).

O dataset está relacionado a pessoas? Caso contrário, você pode ignorar as perguntas restantes desta seção.

Sim. Ambos os datasets contêm gravações respiratórias de pacientes reais, juntamente com algumas informações demográficas e clínicas.

Os dados foram coletados diretamente dos indivíduos em questão ou obtidos por terceiros ou outras fontes (por exemplo, websites)?

Os dados foram coletados diretamente dos pacientes durante exames clínicos e procedimentos de ausculta respiratória.

Os indivíduos em questão foram notificados sobre a coleta dos dados? Se sim, descreva como essa notificação foi fornecida.

No KAUH, o artigo informa que os participantes, ou seus responsáveis legais no caso de menores de idade, forneceram consentimento informado por escrito. No ICBHI, não foram encontradas descrições detalhadas sobre os mecanismos de notificação aos participantes.

Os indivíduos em questão consentiram com a coleta e o uso de seus dados? Se sim, descreva como o consentimento foi solicitado e fornecido.

No KAUH, os autores informam explicitamente que os participantes forneceram consentimento informado por escrito autorizando a utilização e compartilhamento dos dados. No ICBHI, o artigo informa apenas que houve aprovação ética institucional, sem detalhar os procedimentos de consentimento.

Caso o consentimento tenha sido obtido, os indivíduos tiveram acesso a algum mecanismo para revogar esse consentimento futuramente ou para usos específicos? Se sim, forneça uma descrição.

Não foram encontradas informações sobre a revogação de consentimento em nenhum dos dois datasets.

Foi realizada alguma análise do impacto potencial do dataset e de seu uso sobre os indivíduos participantes (por exemplo, uma análise de impacto de proteção de dados)? Se sim, forneça uma descrição dessa análise, incluindo resultados e documentação de suporte.

Não foram encontradas informações sobre análises de impacto relacionadas à proteção de dados ou privacidade dos participantes.

Pré-processamento/Limpeza/Rotulagem

Foi realizado algum pré-processamento, limpeza ou rotulagem dos dados (por exemplo, discretização, agrupamento em faixas, tokenização, marcação gramatical, extração de características SIFT, remoção de instâncias ou tratamento de valores ausentes)? Se sim,

forneça uma descrição. Caso contrário, você pode ignorar as perguntas restantes desta seção.

Sim. No ICBHI, os áudios foram anotados por especialistas indicando fases respiratórias e presença de sons adventícios, como sibilos e estalos. Além disso, em arquivos de texto separados, foram incluídos os diagnósticos das amostras, informações técnicas como região do tórax onde foi adquirida a gravação e equipamento, e informações demográficas dos pacientes, como sexo, idade, peso, altura, etc. No KAUH, os áudios foram exportados utilizando três filtros do software Littmann StethAssist (Bell, Diaphragm e Extended), enfatizando diferentes faixas de frequência. Os nomes dos arquivos também incluem informações técnicas, como local de medição do tórax, e demográficas, como sexo e idade. Não foram encontradas informações sobre remoção de instâncias ou tratamento de valores ausentes.

Os dados “brutos” foram armazenados além dos dados pré-processados/limpos/rotulados (por exemplo, para permitir usos futuros não previstos)? Se sim, forneça um link ou outro meio de acesso aos dados brutos.

Ambos os datasets disponibilizam os áudios brutos. No ICBHI, são disponibilizados os arquivos de áudio, anotações e informações clínicas/demográficas. No KAUH, além dos arquivos “.wav”, também são disponibilizados arquivos originais “.zsa” exportados diretamente do estetoscópio eletrônico.

O software utilizado para pré-processar/limpar/rotular as instâncias está disponível? Se sim, forneça um link ou outro meio de acesso.

No ICBHI, o artigo cita o uso do Respiratory Sound Annotation Software e do Audacity para anotação dos sons respiratórios¹. No KAUH, o artigo cita o uso do software Littmann StethAssist para exportação e visualização das gravações: ²

Uso

¹<https://www.scitepress.org/papers/2012/37563/37563.pdf>

²<https://multimedia.3m.com/mws/media/594653O/3m-littmann-stethassist-visualization-software-user-manual.pdf>

O conjunto de dados já foi utilizado em alguma tarefa? Se sim, forneça uma descrição.

Sim, existem outros trabalhos que fazem uso do dataset bruto disponibilizado pelos autores.

Existe algum repositório que inclua links para artigos ou todos os artigos ou sistemas que utilizam o conjunto de dados? Se sim, indique um link ou outro meio de acesso.

Não, o mendeley mostra o número de citações mas não é possível ver quais artigos. Para o ICBHI2017 também não há.

Para que (outras) tarefas poderia o conjunto de dados ser utilizado?

É possível fazer a classificação da presença não apenas das doenças pulmonares, mas aspectos que direcionam a possibilidade de doenças como síblos e estalos.

Existe algum aspecto relacionado com a composição do conjunto de dados ou com a forma como foi recolhido e pré-processado/limpo/rotulado que possa afetar utilizações futuras? Por exemplo, há algo que um futuro usuário possa precisar de saber para evitar utilizações que possam resultar em tratamento injusto de indivíduos ou grupos (por exemplo, estereótipos, problemas de qualidade do serviço) ou outros danos indesejáveis (por exemplo, prejuízos financeiros, riscos legais)? Se sim, forneça uma descrição. Há algo que um futuro usuário possa fazer para mitigar esses danos indesejáveis?

Ambos os datasets brutos apresentam as rotulações via arquivo em texto. Se não for bem manipulado, pode ocasionar na rotulação equivocada e até mesmo no pré-processamento inadequado que leva em conta o tipo da amostra.

Existem tarefas para as quais o conjunto de dados não deve ser utilizado? Se sim, forneça uma descrição.

Apenas as tarefas que não são pertinentes para o uso dos audios. Que distoam completamente do contexto de doenças pulmonares.

O dataset será distribuído a terceiros fora da entidade (por exemplo, empresa, instituição, organização) em nome da qual foi criado? Se for o caso, forneça uma descrição.

A licença MIT permite que seja usado. Todavia, diretamente e de forma ativa não será disponibilizado para elas.

Como será distribuído o dataset (por exemplo, arquivo tar no site, API, GitHub) ? O conjunto de dados possui um identificador de objeto digital (DOI)?

O dataset bruto possui doi e site próprio (tanto o do challenge³) quanto o disposto no mendeley⁴). Já o dataset utilizado nesse trabalho se encontrará no github.

Quando será disponibilizado o conjunto de dados?

O dataset bruto já está disponível, enquanto o utilizado no trabalho da disciplina será posto no github em breve.

O dataset será distribuído ao abrigo de uma licença de direitos de autor ou de outra licença de propriedade intelectual (PI) e/ou ao abrigo dos termos de utilização (ToU) aplicáveis? Se for esse o caso, descreva essa licença e/ou os ToU e forneça um link ou outro meio de acesso, ou reproduza de outra forma, quaisquer termos de licenciamento ou ToU relevantes, bem como quaisquer taxas associadas a essas restrições.

O dataset préprocessado estará sujeito a Licença MIT no github. Já o dataset bruto presente no mendeley está associado a Creative Commons Attribution 4.0 International licence. Por outro lado, o dataset bruto do ICBHI2017 não apresenta licença.

Algum terceiro impôs restrições relacionadas com direitos de propriedade intelectual ou de outra natureza aos dados associados às instâncias? Se for o caso, descreva essas restrições e forneça um link ou outro meio de acesso, ou reproduza, quaisquer termos de licenciamento relevantes, bem como quaisquer taxas associadas a essas restrições.

³https://bhichallenge.med.auth.gr/ICBHI_2017_Challenge

⁴<https://data.mendeley.com/datasets/jwyy9np4gv/3>

Não se Aplica.

Existem algum controle de exportação ou outras restrições regulamentares aplicáveis ao dataset ou a instâncias individuais? Se for o caso, descreva essas restrições e forneça um link ou outro meio de acesso à documentação de apoio, ou reproduza-a de outra forma.

Não se aplica.

Manutenção

Quem irá apoiar/hospedar/manter o conjunto de dados?

Os datasets brutos são hospedados em site próprio e no mendeley. Já o dataset processado em visuais os quais serão trabalhados pelo grupo, será mantido pelo próprio grupo via github.

Como é que se pode contactar o proprietário/curador/gestor do conjunto de dados (por exemplo, endereço de e-mail)?

O dataset bruto ICBHI2017 pode ser contatado via email (icbhi_challenge@med.auth.gr). Já os autores do dataset bruto do mendeley dispoem do email (fraiwan@just.edu.jo) apresentado no artigo referente ao dataset.

Existe alguma errata? Se sim, por favor, forneça um link ou outro meio de acesso.

Não se Aplica.

O dataset será atualizado (por exemplo, para corrigir erros de rotulagem, adicionar novas instâncias ou eliminar instâncias)? Se sim, descreva com que frequência, por quem e como as atualizações serão comunicadas aos utilizadores (por exemplo, lista de correio, GitHub)?

O dataset pode ser atualizado pelo grupo a medida que erros forem encontrados. O dataset pode ser versionado no próprio github.

Se o conjunto de dados se referir a pessoas, existem limites aplicáveis à conservação dos dados associados a esses registos (por exemplo, foi comunicado às pessoas em questão

que os seus dados seriam conservados durante um período de tempo determinado e, posteriormente, eliminados)? Em caso afirmativo, descreva esses limites e explique como serão aplicados.

Não se Aplica.

As versões anteriores do conjunto de dados continuarão a ser suportadas/hospedadas/mantidas? Em caso afirmativo, descreva como. Caso contrário, descreva como a sua obsolescência será comunicada aos utilizadores.

Sim. o GitHub permite isso. Além disso, o dataset bruto disposto no mendeley é versionado na própria plataforma. Já o dataset ICBHI2017 não apresenta outras versões.

Se outras pessoas quiserem ampliar, complementar, desenvolver ou contribuir para o conjunto de dados, existe algum mecanismo que lhes permita fazê-lo? Se sim, forneça uma descrição. Essas contribuições serão validadas ou verificadas? Se sim, descreva como. Se não, por que razão não? Existe algum processo para comunicar ou distribuir essas contribuições a outros utilizadores? Se sim, forneça uma descrição.

Sim, o próprio github tem a opção de contribuintes para o projeto, o qual pode ser analisado e aceito pelos proprietários.

Algum outro comentário?